



Solutions-architect

AWS Solutions Architect Associate (SAA-C03)

Curso completo com 4 módulos

Segurança • Resiliência • Performance • Custos

CloudTrilhas — cloudtrilhas.com.br

Por Ricardo Simines Scopim

 Solutions Architect — Domínio 01

Design de Arquiteturas Seguras

IAM, VPC, criptografia, serviços de segurança, Organizations e governança. Este domínio representa 30% do exame.

1. IAM — Identity and Access Management

Policies e Permissões

Identity-based Policies USUÁRIO/ROLE

Tipos de policies:

- AWS Managed – criadas e mantidas pela AWS
- Customer Managed – criadas pelo cliente (reusáveis)
- Inline – embutidas diretamente no usuário/grupo/role

Avaliação de permissões:

1. Deny explícito → SEMPRE nega
2. Allow explícito → permite (se não há deny)
3. Deny implícito → padrão (sem policy = sem acesso)

Princípio do menor privilégio:

- Conceder apenas permissões necessárias
- Usar conditions para restringir (IP, MFA, horário)
- Revisar com IAM Access Analyzer

Resource-based Policies RECURSO

Aplicadas diretamente ao recurso:

- S3 Bucket Policies
- SQS Queue Policies
- KMS Key Policies
- Lambda Resource Policies

Diferença-chave:

- Identity-based: "O que este usuário pode fazer?"
- Resource-based: "Quem pode acessar este recurso?"

Cross-account:

- Resource-based permite acesso cross-account sem assumir role (Principal de outra conta)
- Útil para compartilhar S3, KMS, SQS entre contas

IAM Roles e Cross-Account Access

IAM Roles TEMPORÁRIO

Roles fornecem credenciais temporárias (STS):

- Não têm credenciais permanentes
- Assumidas por usuários, serviços ou contas externas

Casos de uso:

- EC2 Instance Profile (role para EC2)
- Lambda Execution Role
- Cross-account access
- Federation (SAML, OIDC)

Trust Policy:

- Define QUEM pode assumir a role
- Permissions Policy define O QUE a role pode fazer

Cross-Account Access MULTI-CONTA

Padrão para acesso entre contas AWS:

1. Conta B cria Role com Trust Policy
→ Principal: `arn:aws:iam::CONTA-A:root`
2. Conta A concede `sts:AssumeRole` para a role da Conta B
3. Usuário na Conta A assume a role da Conta B
→ Recebe credenciais temporárias

Alternativas:

- Resource-based policies (S3, KMS)
- AWS Resource Access Manager (RAM)
- Organizations + SCPs para governança

 **Para o exame:** IAM Roles são SEMPRE preferíveis a access keys. Cross-account = Role + Trust Policy. MFA deve ser exigido para ações sensíveis. IAM Access Analyzer identifica recursos compartilhados externamente.

2. VPC — Virtual Private Cloud

Subnets e Roteamento

Subnets REDE

Subnet Pública:

- Route table com rota para Internet Gateway (IGW)
- Recursos com IP público acessam internet
- Ex: ALB, NAT Gateway, Bastion Host

Subnet Privada:

- Sem rota direta para IGW
- Acesso à internet via NAT Gateway (em subnet pública)
- Ex: EC2 de aplicação, RDS, ElastiCache

Boas práticas:

- Mínimo 2 AZs para alta disponibilidade
- Subnets separadas por tier (web, app, data)
- CIDR planning para evitar conflitos

VPC Endpoints PRIVADO

Acesso a serviços AWS sem passar pela internet:

Interface Endpoint (PrivateLink):

- ENI na subnet com IP privado
- Suporta: S3, DynamoDB, SQS, SNS, KMS, etc.
- Security Groups aplicáveis
- Custo por hora + dados transferidos

Gateway Endpoint (gratuito):

- Entrada na route table
- Apenas S3 e DynamoDB
- Sem custo adicional
- Preferível para S3/DynamoDB

💡 Gateway Endpoint para S3/DynamoDB

Interface Endpoint para demais serviços

NACLs vs Security Groups

Security Groups **STATEFUL**

- Nível de instância (ENI)
- STATEFUL – retorno automático permitido
- Apenas regras ALLOW (sem deny explícito)
- Avalia TODAS as regras antes de decidir
- Pode referenciar outro SG como source

Exemplo:

- SG-Web: permite 80/443 de 0.0.0.0/0
- SG-App: permite 8080 de SG-Web
- SG-DB: permite 3306 de SG-App

NACLs **STATELESS**

- Nível de subnet
- STATELESS – precisa regra de entrada E saída
- Regras ALLOW e DENY
- Avalia regras em ORDEM numérica (primeira match)
- Default NACL permite tudo

Quando usar NACLs:

- Bloquear IPs específicos (deny)
- Camada extra de defesa
- Compliance requirements

⚠ Ephemeral ports (1024-65535) devem ser permitidos na saída para respostas

Conectividade

VPC Peering 1:1

- Conexão direta entre 2 VPCs
- Mesmo ou diferente account/region
- NÃO transitivo ($A \leftrightarrow B$, $B \leftrightarrow C \neq A \leftrightarrow C$)
- CIDRs não podem se sobrepor
- Precisa atualizar route tables em ambos lados

Limitações:

- Não escala para muitas VPCs
- Cada par precisa de peering separado
- Para muitas VPCs → Transit Gateway

Transit Gateway HUB

- Hub central para conectar múltiplas VPCs
- Suporta VPN e Direct Connect
- TRANSITIVO — todas VPCs se comunicam via hub
- Cross-region peering entre TGWs
- Route tables para controle granular

Casos de uso:

- Muitas VPCs (>3) precisam se comunicar
- Arquitetura hub-and-spoke
- Shared services VPC
- Conectividade híbrida centralizada

 **Para o exame:** SG = stateful (só allow) | NACL = stateless (allow + deny). VPC Peering = não transitivo. Transit Gateway = transitivo, hub central. VPC Endpoints eliminam necessidade de NAT/IGW para serviços AWS.

3. Criptografia e Proteção de Dados

AWS KMS

CHAVES

Key Management Service:

Tipos de chaves:

- AWS Managed Keys – criadas/gerenciadas pela AWS
(aws/s3, aws/ebs, aws/rds)
- Customer Managed Keys (CMK) – controle total
(rotação, policies, auditoria)
- AWS Owned Keys – usadas internamente pela AWS

Envelope Encryption:

1. KMS gera Data Key (plaintext + encrypted)
2. Data Key criptografa os dados
3. Plaintext key é descartada da memória
4. Encrypted data key armazenada junto aos dados

Rotação automática:

- AWS Managed: a cada 1 ano (automático)
- Customer Managed: configurável (anual)

Encryption at Rest **ARMAZENAMENTO**

S3 Encryption:

- SSE-S3: chave gerenciada pela AWS (padrão)
- SSE-KMS: chave KMS (auditoria via CloudTrail)
- SSE-C: chave fornecida pelo cliente
- Client-side: criptografa antes de enviar

EBS Encryption:

- AES-256 via KMS
- Snapshots de volumes encrypted são encrypted
- Volumes criados de snapshots encrypted são encrypted
- Não é possível remover encryption de volume existente

RDS Encryption:

- Ativada na criação (não pode ativar depois)
- Read replicas herdam encryption
- Snapshots de DB encrypted são encrypted
- Para criptografar DB existente:
snapshot → copy com encryption → restore

 **Para o exame:** SSE-KMS permite auditoria via CloudTrail. Envelope Encryption para dados grandes. Para criptografar RDS existente: snapshot → copy encrypted → restore. S3 default encryption = SSE-S3.

4. Serviços de Segurança AWS

Serviço	Função	Quando Usar
AWS WAF	Web Application Firewall	Proteger ALB/CloudFront/API Gateway contra SQL injection, XSS, rate limiting, geo-blocking
AWS Shield	Proteção DDoS	Standard (gratuito, L3/L4) Advanced (\$3k/mês, L7, DRT team, cost protection)
Amazon GuardDuty	Deteção de ameaças	Análise de VPC Flow Logs, DNS logs, CloudTrail — detecta comportamento malicioso
Amazon Inspector	Vulnerability scanning	Scan de EC2, containers ECR e Lambda para CVEs e network exposure
Amazon Macie	Proteção de dados sensíveis	Descobrir e proteger PII/dados sensíveis em S3 usando ML
AWS Config	Compliance e auditoria	Avaliar configurações de recursos contra regras de compliance (ex: EBS encrypted)
CloudTrail	Auditoria de API calls	Registrar TODAS as chamadas de API — quem fez o quê, quando, de onde
Security Hub	Central de segurança	Agregar findings de GuardDuty, Inspector, Macie, Config em um dashboard

 **Para o exame:** WAF = camada 7 (HTTP). Shield Standard = gratuito (L3/L4). GuardDuty = detecção inteligente de ameaças. Inspector = vulnerabilidades. Macie = dados sensíveis em S3. Config = compliance de configuração.

5. AWS Organizations e Governança

Organizations MULTI-CONTA

Estrutura hierárquica:

- Root → OUs (Organizational Units) → Accounts
- Consolidated Billing (fatura única)
- Volume discounts compartilhados

SCPs (Service Control Policies):

- Definem LIMITE MÁXIMO de permissões
- NÃO concedem permissões (apenas restringem)
- Aplicadas a OUs ou contas
- Não afetam a Management Account
- Herança hierárquica (OU pai → OU filho)

Exemplo SCP – bloquear regiões:

```
{
  "Effect": "Deny",
  "Action": "*",
  "Resource": "*",
  "Condition": {
    "StringNotEquals": {
      "aws:RequestedRegion": ["us-east-1", "sa-east-1"]
    }
  }
}
```

AWS SSO / Identity Center ACESSO

AWS IAM Identity Center (ex-SSO):

- Single Sign-On para múltiplas contas AWS
- Integra com Active Directory, Okta, Azure AD
- Permission Sets definem acesso por conta
- Um login → acesso a várias contas/apps

Fluxo:

1. Usuário autentica no Identity Center
2. Seleciona conta e permission set
3. Recebe credenciais temporárias (STS)

Vantagens:

- Gerenciamento centralizado de acesso
- Auditoria unificada
- Sem necessidade de IAM users por conta
- Suporta SAML 2.0 e OIDC

💡 Identity Center é a recomendação AWS para gerenciar acesso multi-conta

CloudTrail + Config AUDITORIA

CloudTrail:

- Registra TODAS as API calls (Management Events por padrão)
- Data Events (S3 object-level, Lambda invocations) – custo adicional
- Multi-region trail recomendado
- Integração com CloudWatch Logs para alertas
- Organization Trail para todas as contas

AWS Config:

- Avalia configurações contra regras
- Config Rules: managed (AWS) ou custom (Lambda)
- Remediation automática com SSM Automation
- Aggregator para visão multi-conta/multi-região
- Exemplos: s3-bucket-public-read-prohibited, encrypted-volumes, required-tags



Solutions Architect — Domínio 02

Design de Arquiteturas Resilientes

Alta disponibilidade, Auto Scaling, Load Balancing, Route 53, replicação, bancos de dados e estratégias de DR. Este domínio representa 26% do exame.

1. Alta Disponibilidade (High Availability)

Multi-AZ

REGIONAL

Availability Zones (AZs):

- Data centers isolados dentro de uma região
- Conectados por rede de baixa latência
- Falha de uma AZ não afeta outras

Padrão Multi-AZ:

- Distribuir recursos em 2+ AZs
- ALB roteia entre AZs automaticamente
- Auto Scaling lança em múltiplas AZs
- RDS Multi-AZ: standby síncrono em outra AZ

Serviços inerentemente Multi-AZ:

- S3 (replicação automática em 3+ AZs)
- DynamoDB (replicação em 3 AZs)
- ELB (distribui entre AZs)
- Lambda (executa em múltiplas AZs)

Multi-Region GLOBAL

Quando usar Multi-Region:

- DR com RPO/RTO muito baixos
- Latência global (usuários em vários continentes)
- Compliance (dados em região específica)

Serviços Multi-Region:

- Route 53 (DNS global, failover)
- CloudFront (CDN global)
- S3 Cross-Region Replication
- DynamoDB Global Tables
- Aurora Global Database
- AWS Global Accelerator

Considerações:

- Custo significativamente maior
- Complexidade operacional
- Data sovereignty e compliance
- Consistência eventual entre regiões

2. Auto Scaling

Scaling Policies POLÍTICAS

Target Tracking (recomendado):

- Define métrica alvo (ex: CPU = 50%)
- ASG ajusta automaticamente para manter o target
- Simples e eficiente para maioria dos casos

Step Scaling:

- Define steps baseados em alarmes CloudWatch
- Ex: CPU > 70% → +2 instâncias
CPU > 90% → +4 instâncias
- Mais controle granular

Simple Scaling:

- Uma ação por alarme
- Cooldown period entre ações
- Menos usado (prefer target tracking)

Scheduled Scaling:

- Escala em horários pré-definidos
- Ex: +10 instâncias às 8h, -10 às 20h
- Para padrões de carga previsíveis

ASG Configuration CONFIG

Launch Template:

- AMI, instance type, key pair, SGs
- User data (bootstrap scripts)
- Suporta múltiplos instance types
- Versioning (v1, v2, Latest)

ASG Settings:

- Min / Max / Desired capacity
- Health check type: EC2 ou ELB
- Health check grace period
- Cooldown period (default 300s)
- Termination policies

Lifecycle Hooks:

- Pending:Wait → executar ações antes de InService
- Terminating:Wait → executar antes de terminar
- Útil para: drain connections, backup logs

Instance Refresh:

- Rolling update de instâncias
- Min healthy percentage
- Útil para deploy de nova AMI

 **Para o exame:** Target Tracking é a política recomendada. Launch Template > Launch Configuration (deprecated). Health check ELB é mais preciso que EC2. Lifecycle hooks para ações pré/pós scaling.

3. Elastic Load Balancing (ELB)

Característica	ALB (Application)	NLB (Network)	CLB (Classic)
Camada	Layer 7 (HTTP/HTTPS)	Layer 4 (TCP/UDP/TLS)	Layer 4 e 7 (legacy)
Performance	Boa	Ultra-alta (milhões req/s)	Básica
IP Estático	Não (use Global Accelerator)	Sim (Elastic IP por AZ)	Não
Roteamento	Path, host, header, query string	Port-based	Básico
WebSocket	Sim	Sim	Não
SSL Termination	Sim	Sim (TLS)	Sim
Sticky Sessions	Sim (cookie)	Sim (source IP)	Sim
Caso de uso	Web apps, microserviços, containers	Gaming, IoT, ultra-low latency	Legacy (evitar)

Health Checks MONITORAMENTO

Configurações:

- Protocol: HTTP, HTTPS, TCP
- Path: /health (endpoint dedicado)
- Interval: 5-300s (default 30s)
- Threshold: healthy/unhealthy count
- Timeout: tempo máximo de resposta

Comportamento:

- Target unhealthy → para de receber tráfego
- Target healthy novamente → volta a receber
- Cross-zone load balancing distribui uniformemente

💡 Sempre criar endpoint /health dedicado que verifica dependências (DB, cache)

Sticky Sessions AFINIDADE

Application-based (ALB):

- Cookie customizado ou gerado pelo ALB
- Duração configurável
- Útil para sessões stateful

Problemas com sticky sessions:

- Distribuição desigual de carga
- Dificulta scaling
- Se instância falha, sessão é perdida

Alternativas (preferíveis):

- Sessões em ElastiCache (Redis)
- Sessões em DynamoDB
- JWT tokens (stateless)
- Cookies client-side criptografados

💡 Exame: se perguntam sobre "manter sessão"
→ ElastiCache/DynamoDB > sticky sessions

4. Route 53 — DNS e Routing Policies

Routing Policy	Descrição	Caso de Uso
Simple	Um registro, um ou mais valores (retorna todos, cliente escolhe aleatório)	Aplicação single-server, sem health check
Weighted	Distribui tráfego por peso (ex: 70/30)	Blue/green deployment, A/B testing, migração gradual
Latency-based	Roteia para região com menor latência para o usuário	Aplicações multi-region, melhor experiência global
Failover	Primary/Secondary — failover automático via health check	DR ativo-passivo, alta disponibilidade
Geolocation	Roteia baseado na localização geográfica do usuário	Conteúdo localizado, compliance de dados, restrição regional
Geoproximity	Roteia baseado na proximidade geográfica com bias configurável	Shift de tráfego entre regiões (Traffic Flow)
Multi-value	Retorna múltiplos IPs saudáveis (até 8), com health check	Client-side load balancing simples

 **Para o exame:** Failover = DR. Weighted = deploy gradual. Latency = melhor performance global. Geolocation = compliance/localização. Health checks são obrigatórios para failover.

5. S3 — Replicação e Versionamento

Replication CÓPIA

Cross-Region Replication (CRR):

- Replica objetos para bucket em outra região
- Casos: DR, compliance, latência
- Requer versioning habilitado em ambos

Same-Region Replication (SRR):

- Replica dentro da mesma região
- Casos: agregação de logs, compliance, replicação entre contas na mesma região

Regras:

- Versioning OBRIGATÓRIO (source e destination)
- Pode replicar para outra conta AWS
- Objetos existentes NÃO são replicados (apenas novos)
 - Use S3 Batch Replication para existentes
- Delete markers podem ser replicados (opcional)
- Não há replicação em cadeia (A→B→C não funciona)

Versioning HISTÓRICO

S3 Versioning:

- Mantém todas as versões de um objeto
- Protege contra deleção acidental
- Uma vez habilitado, não pode ser desabilitado (apenas suspenso)

Delete Marker:

- DELETE em objeto versionado cria delete marker
- Objeto "desaparece" mas versões anteriores existem
- Para restaurar: deletar o delete marker

MFA Delete:

- Requer MFA para deletar versões permanentemente
- Proteção extra contra deleção maliciosa
- Apenas root account pode habilitar

Lifecycle + Versioning:

- Mover versões antigas para classes mais baratas
- Expirar versões antigas após X dias
- Limpar incomplete multipart uploads

6. RDS, Aurora e Bancos de Dados

RDS Multi-AZ HA

Multi-AZ Deployment:

- Standby síncrono em outra AZ
- Failover automático (1-2 minutos)
- Mesmo endpoint DNS (sem mudança na app)
- NÃO é para read scaling (standby não aceita reads)

Read Replicas:

- Replicação ASSÍNCRONA
- Até 5 read replicas por DB
- Podem estar em outra AZ ou região
- Endpoint próprio (app precisa apontar)
- Podem ser promovidas a standalone DB
- Cross-region para DR

Multi-AZ vs Read Replica:

- Multi-AZ = HA (failover automático)
- Read Replica = Performance (read scaling)
- Podem ser combinados!

Amazon Aurora MANAGED

Aurora vs RDS:

- 5x performance do MySQL, 3x do PostgreSQL
- Storage auto-scaling (10GB → 128TB)
- 6 cópias dos dados em 3 AZs
- Self-healing storage

Aurora Replicas:

- Até 15 read replicas (vs 5 no RDS)
- Failover automático para replica (< 30s)
- Reader endpoint (load balance entre replicas)

Aurora Serverless:

- Auto-scaling de compute (ACUs)
- Escala para zero quando ocioso
- Pay-per-use
- Bom para: workloads intermitentes, dev/test

Aurora Global Database:

- Replicação cross-region (< 1s lag)
- Até 5 secondary regions
- RPO < 1s, RTO < 1 minuto
- Promoted region em caso de DR

7. Estratégias de Disaster Recovery

Estratégia	RTO	RPO	Custo	Descrição
Backup & Restore	Horas	Horas	💰	Backups em S3/outra região. Restaura quando necessário. Mais barato, mais lento.
Pilot Light	10s min	Minutos	💰💰	Core mínimo rodando (DB replicado). Escala compute quando necessário.
Warm Standby	Minutos	Segundos	💰💰💰	Versão reduzida da produção rodando. Scale up quando ativado.
Active-Active (Multi-site)	~0	~0	💰💰💰💰	Full production em 2+ regiões. Tráfego distribuído. Mais caro, mais rápido.

AWS Backup **CENTRALIZADO**

Serviço centralizado de backup:

- Suporta: EC2, EBS, RDS, Aurora, DynamoDB, EFS, S3, FSx
- Backup Plans: schedule, retention, lifecycle
- Cross-region e cross-account backup
- Vault Lock: WORM (Write Once Read Many) para compliance
- Point-in-time recovery para serviços suportados

Boas práticas:

- Backup automático com retention policies
- Cross-region para DR
- Testar restore regularmente
- Vault Lock para proteção contra ransomware
- Tags para organização e compliance

 **Para o exame:** Backup/Restore = mais barato, maior RTO. Active-Active = mais caro, menor RTO. Pilot Light = DB replicado + compute sob demanda. RPO = quanto dado posso perder. RTO = quanto tempo posso ficar offline.

 Solutions Architect — Domínio 03

Design de Arquiteturas de Alta Performance

EC2, EBS, S3, CloudFront, Global Accelerator, ElastiCache, DynamoDB, Lambda, containers e streaming. Este domínio representa 24% do exame.

1. EC2 — Compute

Instance Families TIPOS

Famílias de instâncias (mnemônico):

General Purpose (M, T):

- M6i, M7g — workloads balanceados
- T3, T4g — burstable (créditos CPU)

Compute Optimized (C):

- C6i, C7g — batch, ML inference, gaming, HPC

Memory Optimized (R, X, z):

- R6i — caches, in-memory DBs
- X2idn — SAP HANA, grandes datasets
- z1d — alta frequência de clock

Storage Optimized (I, D, H):

- I4i — alto IOPS (databases)
- D3 — data warehousing, HDFS
- H1 — throughput sequencial

Accelerated Computing (P, G, Inf, Trn):

- P5 — ML training (GPU NVIDIA)
- G5 — graphics, video encoding
- Inf2 — ML inference (Inferentia)
- Trn1 — ML training (Trainium)

Placement Groups POSICIONAMENTO

Cluster:

- Instâncias no MESMO rack/AZ
- Menor latência possível (10 Gbps entre instâncias)
- Risco: se rack falha, todas falham
- Uso: HPC, big data jobs, low-latency apps

Spread:

- Instâncias em hardware DIFERENTE
- Máximo 7 instâncias por AZ por grupo
- Minimiza risco de falha correlacionada
- Uso: aplicações críticas, HA

Partition:

- Grupos de instâncias em partições isoladas
- Cada partição em rack diferente
- Até 7 partições por AZ
- Uso: HDFS, HBase, Cassandra, Kafka

Enhanced Networking (ENA):

- Até 100 Gbps
- Menor latência, maior PPS
- Sem custo adicional
- Requer driver ENA na AMI

2. EBS — Elastic Block Store

Tipo	IOPS Máx	Throughput Máx	Caso de Uso
gp3 (General Purpose SSD)	16.000	1.000 MB/s	Boot volumes, dev/test, apps gerais. IOPS e throughput independentes do tamanho.
gp2 (General Purpose SSD)	16.000	250 MB/s	Legacy. IOPS = 3 × GB (burst até 3.000). Prefer gp3.
io2 Block Express (Provisioned IOPS)	256.000	4.000 MB/s	Databases críticos, SAP HANA, workloads I/O intensivos.
io2 (Provisioned IOPS)	64.000	1.000 MB/s	Databases que precisam de IOPS consistente e previsível.
st1 (Throughput Optimized HDD)	500	500 MB/s	Big data, data warehouses, log processing. Não pode ser boot volume.
sc1 (Cold HDD)	250	250 MB/s	Dados acessados raramente, menor custo. Não pode ser boot volume.

 **Para o exame:** gp3 é o padrão recomendado. io2 para databases com IOPS garantido. st1/sc1 = HDD (não pode ser boot). Multi-Attach (io1/io2) permite até 16 instâncias no mesmo volume. EBS é single-AZ — use snapshots para cross-AZ/region.

3. S3 — Performance

Transfer Acceleration **UPLOAD**

S3 Transfer Acceleration:

- Usa edge locations da CloudFront para upload
- Dados viajam pela rede backbone da AWS
- 50-500% mais rápido para uploads distantes
- Endpoint: bucketname.s3-accelerate.amazonaws.com
- Custo adicional por GB transferido

Quando usar:

- Uploads de regiões distantes do bucket
- Transferências intercontinentais
- Clientes distribuídos globalmente

Multipart Upload:

- OBRIGATÓRIO para objetos > 5GB
- Recomendado para > 100MB
- Upload paralelo de partes
- Retry de partes individuais (sem recomeçar tudo)
- Abort incomplete uploads (lifecycle rule)

S3 Performance Limits ESCALA

Limites por prefixo:

- 3.500 PUT/COPY/POST/DELETE por segundo
- 5.500 GET/HEAD por segundo
- Por prefixo! Mais prefixos = mais throughput

Otimização de prefixos:

- Distribuir objetos em múltiplos prefixos
- Ex: /images/2024/01/, /images/2024/02/
- Cada prefixo tem seus próprios limites

S3 Select / Glacier Select:

- Filtrar dados com SQL no lado do servidor
- Retorna apenas dados necessários
- Reduz transferência de dados em até 400%
- Reduz custo de transferência

Byte-Range Fetches:

- Download paralelo de partes do objeto
- Acelera downloads grandes
- Retry de ranges específicos

4. CloudFront — CDN

Origins e Behaviors CONFIG

Origins (fontes de conteúdo):

- S3 Bucket (com OAC para acesso privado)
- ALB / EC2 (custom origin)
- API Gateway
- MediaStore / MediaPackage

Behaviors (regras de roteamento):

- Path pattern: /images/*, /api/*, /static/*
- Cada behavior → origin específico
- Cache policy por behavior
- Viewer protocol policy (HTTP→HTTPS redirect)

OAC (Origin Access Control):

- Substitui OAI (legacy)
- S3 bucket pode ser privado
- Apenas CloudFront acessa o bucket
- Suporta SSE-KMS
- Mais seguro que OAI

Cache Policies

PERFORMANCE

Cache Key:

- Define o que diferencia objetos no cache
- Headers, query strings, cookies incluídos
- Menos itens no cache key = melhor hit ratio

TTL (Time to Live):

- Min TTL, Max TTL, Default TTL
- Cache-Control headers do origin
- Invalidation para forçar refresh (custo)

Cache Policies (managed):

- CachingOptimized – máximo cache
- CachingDisabled – sem cache (proxy)
- Custom – controle granular

Origin Request Policy:

- O que enviar ao origin (separado do cache key)
- Pode enviar headers sem afetar cache

Lambda@Edge / CloudFront Functions:

- Código na edge para manipular requests/responses
- CloudFront Functions: leve, viewer events
- Lambda@Edge: mais poder, origin events

5. AWS Global Accelerator

Global Accelerator vs CloudFront COMPARAÇÃO

Global Accelerator:

- 2 IPs estáticos anycast globais
- Tráfego entra na edge e viaja pela rede AWS (backbone)
- Melhora performance para TCP/UDP (não apenas HTTP)
- Health checks e failover automático entre regiões
- Sem cache – todo tráfego vai ao origin
- Casos: gaming, IoT, VoIP, APIs não-HTTP

CloudFront:

- CDN com cache na edge
- Otimizado para conteúdo HTTP/HTTPS
- Cache reduz carga no origin
- Ideal para conteúdo estático e dinâmico cacheable

Quando usar Global Accelerator:

- Precisa de IP estático (whitelisting)
- Protocolo não-HTTP (TCP/UDP)
- Failover instantâneo entre regiões
- Não precisa de cache, precisa de routing otimizado
- Gaming multiplayer, financial trading

6. ElastiCache

Redis vs Memcached **COMPARAÇÃO**

Redis:

- Estruturas de dados ricas (strings, lists, sets, hashes)
- Persistência (snapshots, AOF)
- Replicação (Multi-AZ com failover automático)
- Cluster mode (sharding)
- Pub/Sub, Lua scripting
- Backup e restore
- Encryption at rest e in transit

Memcached:

- Simples key-value
- Multi-threaded (melhor para multi-core)
- Sem persistência
- Sem replicação nativa
- Sem backup
- Auto-discovery de nodes

Escolha:

- Redis → persistência, HA, estruturas complexas
- Memcached → cache simples, multi-threaded

Caching Strategies PADRÕES

Lazy Loading (Cache-Aside):

- App verifica cache primeiro
- Cache miss → busca no DB → grava no cache
- Dados podem ficar stale
- Apenas dados requisitados são cacheados

Write-Through:

- App escreve no cache E no DB simultaneamente
- Cache sempre atualizado
- Maior latência de escrita
- Dados nunca ficam stale

TTL (Time to Live):

- Expira dados após tempo definido
- Combina com Lazy Loading
- Balanceia freshness vs performance

Session Store:

- Armazenar sessões de usuário no Redis
- Alternativa a sticky sessions
- Compartilhado entre todas as instâncias
- TTL para expirar sessões inativas

7. DynamoDB

Partition Key Design

MODELAGEM

Partition Key (PK):

- Determina em qual partição o item é armazenado
- DEVE ter alta cardinalidade (muitos valores únicos)
- Distribuição uniforme = melhor performance

Boas PKs: user_id, order_id, device_id

Más PKs: status, date, country (hot partition)

Sort Key (SK):

- Ordena itens dentro da mesma partição
- Permite range queries (begins_with, between)
- Composite key: PK + SK = item único

Padrões de design:

- Single-table design (múltiplas entidades)
- PK: USER#123, SK: ORDER#456
- PK: USER#123, SK: PROFILE
- Overloading de atributos

GSI e DAX **PERFORMANCE**

Global Secondary Index (GSI):

- Nova partition key + optional sort key
- Projeção de atributos (ALL, KEYS_ONLY, INCLUDE)
- Capacidade provisionada separada
- Eventually consistent reads apenas
- Até 20 GSIs por tabela

Local Secondary Index (LSI):

- Mesma partition key, sort key diferente
- Deve ser criado na criação da tabela
- Strongly consistent reads possível
- Até 5 LSIs por tabela

DynamoDB Accelerator (DAX):

- Cache in-memory para DynamoDB
- Microsegundos de latência (vs ms)
- Compatível com API DynamoDB (drop-in)
- Write-through cache
- Ideal para read-heavy workloads
- Cluster Multi-AZ

8. Lambda, ECS/EKS e Kinesis

Lambda Performance SERVERLESS

Concurrency:

- Default: 1.000 concurrent executions/region
- Reserved concurrency: garante para função
- Provisioned concurrency: elimina cold starts

Memory (128MB - 10GB):

- Mais memória = mais CPU proporcional
- 1.769 MB = 1 vCPU completo
- Otimizar: AWS Lambda Power Tuning

Layers:

- Bibliotecas compartilhadas entre funções
- Até 5 layers por função
- Reduz tamanho do deployment package
- Versionadas independentemente

Limites:

- Timeout: máximo 15 minutos
- Payload: 6MB (sync), 256KB (async)
- /tmp storage: 512MB - 10GB
- Deployment package: 50MB (zip), 250MB (unzipped)

ECS/EKS e Kinesis CONTAINERS/STREAM

ECS (Elastic Container Service):

- EC2 launch type: gerencia instâncias
- Fargate launch type: serverless containers
- Task definitions, services, clusters
- ALB integration (dynamic port mapping)

EKS (Elastic Kubernetes Service):

- Kubernetes gerenciado
- Nodes: EC2 ou Fargate
- Para equipes com expertise em K8s
- Portabilidade multi-cloud

Kinesis Data Streams:

- Streaming de dados em tempo real
- Shards: unidade de capacidade
(1 MB/s in, 2 MB/s out por shard)
- Retention: 24h (default) até 365 dias
- Consumers: Lambda, KCL, Kinesis Analytics

Kinesis Data Firehose:

- Delivery stream (near real-time)
- Destinos: S3, Redshift, OpenSearch, Splunk
- Transformação com Lambda
- Sem gerenciamento de shards (auto-scaling)

 **Para o exame:** Lambda = até 15 min, serverless. ECS Fargate = containers serverless. Kinesis Streams = real-time processing. Kinesis Firehose = delivery para S3/Redshift (near real-time, sem gerenciamento).

 Solutions Architect — Domínio 04

Otimização de Custos

Modelos de precificação, storage classes, right-sizing, ferramentas de gerenciamento de custos, data transfer e estratégias serverless. Este domínio representa 20% do exame.

1. Modelos de Precificação EC2

Modelo	Desconto	Compromisso	Caso de Uso
On-Demand	0% (preço cheio)	Nenhum	Workloads imprevisíveis, dev/test, picos curtos. Paga por segundo (Linux) ou hora (Windows).
Reserved Instances (RI)	Até 72%	1 ou 3 anos	Workloads estáveis e previsíveis. Standard RI (não muda) vs Convertible RI (pode trocar família).
Savings Plans	Até 72%	1 ou 3 anos (\$/hora)	Compromisso de gasto (não de instância). Compute SP (EC2+Lambda+Fargate) ou EC2 Instance SP.
Spot Instances	Até 90%	Nenhum (pode ser interrompido)	Workloads tolerantes a interrupção: batch, CI/CD, big data, containers stateless.
Dedicated Hosts	Variável	On-Demand ou Reserved	Compliance, licenças por socket/core (BYOL), requisitos regulatórios.
Dedicated Instances	Variável	On-Demand	Hardware dedicado sem controle de placement. Menos controle que Dedicated Host.

Savings Plans

FLEXÍVEL

Compute Savings Plans:

- Aplica a EC2, Lambda e Fargate
- Qualquer região, família, OS, tenancy
- Mais flexível que RI
- Compromisso: \$/hora por 1 ou 3 anos

EC2 Instance Savings Plans:

- Específico para família em uma região
- Ex: M5 em us-east-1
- Maior desconto que Compute SP
- Flexível em AZ, size, OS

Comparação com RI:

- SP é mais simples de gerenciar
- SP aplica automaticamente o desconto
- RI Standard não pode mudar família
- RI Convertible pode mudar (menor desconto)

💡 Savings Plans é a recomendação atual da AWS para a maioria dos cenários de desconto

Spot Instances ECONOMIA

Como funciona:

- Capacidade ociosa da AWS com desconto
- Preço flutua baseado em oferta/demanda
- AWS pode reclamar com 2 min de aviso
- Spot Fleet: mix de Spot + On-Demand

Estratégias Spot:

- Spot Fleet com diversificação de tipos
- Spot + Auto Scaling (mixed instances)
- Spot Block (1-6 horas, deprecated)

Boas práticas:

- Diversificar instance types e AZs
- Usar checkpointing para jobs longos
- Combinar com On-Demand para baseline
- Spot para scaling, On-Demand para base

NÃO usar Spot para:

- Databases
- Aplicações stateful críticas
- Workloads que não toleram interrupção

2. S3 Storage Classes e Lifecycle

Classe	Disponibilidade	Min Storage	Caso de Uso
S3 Standard	99.99%	—	Dados acessados frequentemente. Sem taxa de retrieval.
S3 Intelligent-Tiering	99.9%	—	Padrão de acesso desconhecido. Move automaticamente entre tiers. Taxa de monitoramento.
S3 Standard-IA	99.9%	30 dias	Acesso infrequente mas precisa de acesso rápido. Taxa de retrieval por GB.
S3 One Zone-IA	99.5%	30 dias	Dados recriáveis, infrequentes. Uma AZ apenas. 20% mais barato que Standard-IA.
S3 Glacier Instant Retrieval	99.9%	90 dias	Arquivo com acesso imediato (ms). Acesso ~1x por trimestre.
S3 Glacier Flexible Retrieval	99.99%	90 dias	Arquivo com retrieval em minutos a horas. Expedited (1-5min), Standard (3-5h), Bulk (5-12h).
S3 Glacier Deep Archive	99.99%	180 dias	Arquivo de longo prazo. Retrieval: Standard (12h), Bulk (48h). Mais barato.

Lifecycle Rules AUTOMAÇÃO

Transition Actions (mover entre classes):

- Standard → Standard-IA (após 30 dias)
- Standard-IA → Glacier Instant (após 60 dias)
- Glacier Instant → Glacier Flexible (após 90 dias)
- Glacier Flexible → Deep Archive (após 180 dias)

Expiration Actions (deletar):

- Expirar objetos após X dias
- Expirar versões anteriores
- Deletar incomplete multipart uploads
- Deletar delete markers expirados

Regras:

- Mínimo 30 dias em Standard antes de transição para IA
- Mínimo 30 dias em IA antes de transição para Glacier
- Pode aplicar por prefixo ou tag
- Versões atuais e anteriores separadamente

💡 S3 Intelligent-Tiering é ideal quando não se conhece o padrão de acesso (sem taxa de retrieval, apenas monitoramento)

3. Right-Sizing

AWS Compute Optimizer

RECOMENDAÇÕES

Analisa métricas e recomenda:

- EC2: instance type ideal
- EBS: volume type e size
- Lambda: memory configuration
- ECS on Fargate: CPU e memory

Baseado em:

- Utilização de CPU, memória, rede
- Histórico de 14 dias (ou mais com Enhanced)
- Machine Learning para prever necessidades

Classificações:

- Over-provisioned → reduzir (economia)
- Under-provisioned → aumentar (performance)
- Optimized → manter

Enhanced Infrastructure Metrics:

- Até 3 meses de histórico
- Recomendações mais precisas
- Custo adicional

CloudWatch Metrics MONITORAMENTO

Métricas para right-sizing:

EC2:

- CPUUtilization (< 10% = over-provisioned)
- NetworkIn/Out
- Disk Read/Write (instance store)
- Nota: memória requer CloudWatch Agent

EBS:

- VolumeReadOps / VolumeWriteOps
- VolumeQueueLength (> 1 = bottleneck)
- BurstBalance (gp2/st1/sc1)

RDS:

- CPUUtilization
- FreeableMemory
- ReadIOPS / WriteIOPS
- DatabaseConnections

Trusted Advisor:

- Low utilization EC2 instances
- Idle Load Balancers
- Underutilized EBS volumes
- Unassociated Elastic IPs

4. Ferramentas de Gerenciamento de Custos

Ferramenta	Função	Quando Usar
AWS Cost Explorer	Visualização e análise de custos	Analisar gastos passados, prever futuros, identificar tendências. Recomendações de RI/SP.
AWS Budgets	Alertas e limites de gastos	Definir orçamentos (custo, uso, RI/SP coverage). Alertas por e-mail/SNS. Budget Actions automáticas.
Cost Anomaly Detection	Deteção de gastos anormais	ML detecta gastos inesperados automaticamente. Alertas proativos. Root cause analysis.
Compute Optimizer	Recomendações de right-sizing	Identificar recursos over/under-provisioned. EC2, EBS, Lambda, ECS.
Cost and Usage Report (CUR)	Relatório detalhado de custos	Dados granulares para análise avançada. Integra com Athena, QuickSight, Redshift.
Billing Conductor	Billing customizado	Criar billing groups, aplicar pricing rules, showback/chargeback para departamentos.

AWS Budgets – Actions AUTOMAÇÃO

Budget Actions (automação de resposta):

- Aplicar IAM policy restritiva quando budget excedido
- Aplicar SCP para bloquear criação de recursos
- Parar instâncias EC2 automaticamente

Tipos de Budget:

- Cost Budget – limite de gasto em \$
- Usage Budget – limite de uso (horas, GB)
- RI Utilization Budget – alerta se RI subutilizado
- RI Coverage Budget – alerta se cobertura RI baixa
- Savings Plans Utilization/Coverage

Alertas:

- Actual (quando atingir X%)
- Forecasted (quando previsão atingir X%)
- Múltiplos thresholds (50%, 80%, 100%)
- Notificação: e-mail, SNS, Chatbot

5. Custos de Data Transfer

Regras de Transfer CUSTO

GRATUITO:

- Inbound (internet → AWS) = grátis
- Dentro da mesma AZ = grátis
- S3 → CloudFront = grátis
- Entre serviços na mesma região (alguns)

PAGO:

- Outbound (AWS → internet) = \$\$
- Entre AZs na mesma região = \$
- Entre regiões = \$\$
- NAT Gateway processing = \$

Otimizações:

- VPC Endpoints (evita NAT Gateway)
- CloudFront (reduz outbound)
- S3 Transfer Acceleration (uploads)
- Manter recursos na mesma AZ quando possível
- Direct Connect (preço menor que internet)

💡 Data transfer é frequentemente o custo "escondido" que surpreende em produção

Serverless Cost Optimization SERVERLESS

Lambda:

- Paga por: requests + duration (GB-seconds)
- Otimizar memória (Power Tuning)
- Provisioned Concurrency tem custo fixo
- ARM (Graviton) = 20% mais barato

API Gateway:

- REST API: por request + data transfer
- HTTP API: 70% mais barato que REST
- WebSocket: por mensagem + connection time

DynamoDB:

- On-Demand: paga por request (RCU/WCU)
- Provisioned: capacidade reservada (mais barato)
- Reserved Capacity: desconto adicional
- Auto Scaling para provisioned

Fargate:

- Paga por vCPU + memória por segundo
- Spot Fargate: até 70% desconto
- Compute Savings Plans aplicável

6. Estratégias de Tagging

Cost Allocation Tags ORGANIZAÇÃO

Tags para alocação de custos:

AWS-generated tags (prefixo aws:):

- aws:createdBy – quem criou o recurso
- Ativadas no Billing Console

User-defined tags:

- Environment: prod, dev, staging
- Project: projeto-x, projeto-y
- Team: backend, frontend, data
- CostCenter: CC-001, CC-002
- Owner: email do responsável

Boas práticas:

- Definir tag policy na Organization
- Enforcement via SCPs ou Config Rules
- Tag Editor para aplicar em massa
- Ativar tags no Cost Explorer para filtrar custos
- Automação: Lambda + EventBridge para tag compliance

Tag Policies (Organizations):

- Define tags obrigatórias e valores permitidos
- Reporta non-compliance
- Não bloqueia criação (apenas reporta)
- Combine com SCPs para enforcement

 **Para o exame:** Savings Plans > RI para flexibilidade. Spot para workloads tolerantes a interrupção. S3 Intelligent-Tiering para padrão desconhecido. VPC Endpoints reduzem custo de NAT. Tags são essenciais para cost allocation. Cost Anomaly Detection usa ML para alertas proativos.